

時系列分析のその他のトピック

見せかけの回帰とその対策

宇畑 優太(1260404)

2024-09-05

目次

準備	2
1 ホワイトノイズへの回帰分析	3
2 単位根のあるデータ同士の回帰分析	4
3 AR 定常過程への回帰分析	6
4 残差の自己相関と見せかけの回帰	7
5 DW 検定	7
6 シミュレーションによる見せかけの回帰	8
7 見せかけの回帰を防ぐ方法	10
8	10
9 単位根検定	10
10 一般化最小二乗法：GLS	13
11 R による Prains-Winsten 法	14
12 差分系列への回帰分析	15
13 共和分	16
14 共和分検定	17

準備

```
## PDF に出力する際は cairo を使用する
if (knitr::is_latex_output()) {
  knitr::opts_chunk$set(dev = "cairo_pdf")
}

#パッケージの読み込み
pacman::p_load(tidyverse,
               broom,
               coefplot,
               texreg,
               bayesplot,
               rstan,
               rstanrm,
               parallel,
               posterior,
               cmdstanr,
               patchwork,
               ggplot2,
               tidybayes,
               ggfortify,
               gridExtra,
               forecast,
               tseries,
               summarytools,
               forecast,
               lmtest,
               urca,
               prais
               )

#日本語の設定
if (.Platform$OS.type == "windows") {
  if (require(fontregisterer)) {
    my_font <- "Yu Gothic"
  } else {
    my_font <- "Japan1"
  }
}
```

```

}
} else if (capabilities("aqua")) {
  my_font <- "HiraginoSans-W3"
} else {
  my_font <- "IPAexGothic"
}

theme_set(theme_gray(base_size = 9,
                     base_family = my_font))

```

```

#計算の高速化
rstan_options(auto_write = TRUE)
options(mc.cores = parallel::detectCores())

```

1 ホワイトノイズへの回帰分析

全く関係ないデータ同士を回帰分析にかけると, 有意な係数は出ないはず.

正規分布に従うホワイトノイズを複数発生させて, 回帰分析を実行してみる

```

#1 回のシミュレーションにおけるサンプルサイズ
n_sample <- 400

#シード値の設定
set.seed(1)

#データの生成
y_wn <- rnorm(n = n_sample)
x_wn <- rnorm(n = n_sample)

#回帰の実行
mod_ols_wn <- lm(y_wn ~ x_wn)

#結果の表示
summary(mod_ols_wn)

```

Call:

```
lm(formula = y_wn ~ x_wn)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.91553	-0.60756	-0.06449	0.65797	2.64718

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.03993	0.04862	0.821	0.412
x_wn	0.02605	0.04500	0.579	0.563

Residual standard error: 0.9704 on 398 degrees of freedom

Multiple R-squared: 0.0008414, Adjusted R-squared: -0.001669

F-statistic: 0.3352 on 1 and 398 DF, p-value: 0.563

p 値をみるに, 統計的有意はない. 当然である

2 単位根のあるデータ同士の回帰分析

ホワイトノイズの累積和として, RW 過程をシミュレーションする

```
#シード値の設定
```

```
set.seed(1)
```

```
#RW 過程
```

```
y_rw <- cumsum(rnorm(n = n_sample))
```

```
x_rw <- cumsum(rnorm(n = n_sample))
```

```
#回帰の実行
```

```
mod_ols_rw <- lm(y_rw ~ x_rw)
```

```
#結果の表示
```

```
summary(mod_ols_rw)
```

Call:

```
lm(formula = y_rw ~ x_rw)
```

Residuals:

Min	1Q	Median	3Q	Max
-9.1820	-3.0629	0.4445	2.6711	8.3003

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.40661	0.29876	18.10	<2e-16 ***
x_rw	-0.28189	0.01738	-16.22	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.622 on 398 degrees of freedom
Multiple R-squared: 0.398, Adjusted R-squared: 0.3965
F-statistic: 263.1 on 1 and 398 DF, p-value: < 2.2e-16

係数が、統計的有意である。

全く関係のない RW 過程を回帰分析にかけると、統計的有意になる。この現象を「見せかけの回帰」と呼ぶ。

図示してみよう

```
#WN

#データの整形
df_wn <- data.frame(x_wn = x_wn, y_wn = y_wn)

#図示
p_wn <- ggplot(df_wn,
               aes(x = x_wn,
                   y = y_wn))+
  geom_point() +
  geom_smooth(method = "lm", color = 1) +
  ggtitle("White-Noise")


#RW

#データの整形
df_rw <- data.frame(x_rw = x_rw, y_rw = y_rw)

#図示
p_rw <- ggplot(df_rw,
               aes(x = x_rw,
                   y = y_rw))+
  geom_point() +
  geom_smooth(method = "lm", color = 1) +
  ggtitle("Random-Walk")
```

```
#表示
```

```
grid.arrange(p_wn, p_rw, ncol = 2)
```



3 AR 定常過程への回帰分析

単位根ではなく, 定常 AR 過程に従うシミュレーション

```
set.seed(1)

#定常 AR 過程に従うデータ
y_ar <- arima.sim(
  n = n_sample,
  model = list(order = c(1,0,0), ar = c(0.8))
)

x_ar <- arima.sim(
  n = n_sample,
  model = list(order = c(1,0,0), ar = c(0.8))
)

#回帰の実行
mod_old_ar <- lm(y_ar ~ x_ar)

#結果
summary(mod_old_ar)
```

Call:

```
lm(formula = y_ar ~ x_ar)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.2996	-0.9923	0.1009	0.9839	4.0034

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.19888	0.07660	2.596	0.00978 **
x_ar	0.08634	0.04955	1.742	0.08223 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.511 on 398 degrees of freedom

Multiple R-squared: 0.007569, Adjusted R-squared: 0.005076

F-statistic: 3.036 on 1 and 398 DF, p-value: 0.08223

有意な回帰係数が得られてしまった。これも「見せかけの回帰」である

4 残差の自己相関と見せかけの回帰

詳細は note

5 DW 検定

詳細は note

```
#DW 統計量
resid_old <- mod_ols_rw$residuals

dw <- sum(diff(resid_old)^2) / sum((resid_old)^2)

dw
```

```
[1] 0.08021259
```

2 ではないので、自己相関がありそう

検定もできる

```
#WN
dwtest(mod_ols_wn)
```

Durbin-Watson test

```
data: mod_ols_wn
DW = 2.0935, p-value = 0.8261
alternative hypothesis: true autocorrelation is greater than 0
```

```
#RW
dwtest(mod_ols_rw)
```

Durbin-Watson test

```
data: mod_ols_rw
DW = 0.080213, p-value < 2.2e-16
alternative hypothesis: true autocorrelation is greater than 0
```

```
#AR(1) 過程
dwtest(mod_old_ar)
```

Durbin-Watson test

```
data: mod_old_ar
DW = 0.48088, p-value < 2.2e-16
alternative hypothesis: true autocorrelation is greater than 0
```

RW と AR 過程に自己相関が見られる

6 シミュレーションによる見せかけの回帰

以下のコードで p 値だけ取り出せる

```
summary(mod_ols_wn)$coefficient["x_wn", "Pr(>|t|)"]
```

```
[1] 0.5629569
```

この作業を何回も繰り返してみよう


```

n_sim <- 200          #シミュレーションの回数

n_sample <- 400       #サンプルサイズ

p_wn <- numeric(n_sim)
p_rw <- numeric(n_sim)

set.seed(1)

for(i in 1:n_sim){
  #自己相関のないシミュデータ
  y_wn <- rnorm(n = n_sample)
  x_wn <- rnorm(n = n_sample)

  #線形回帰分析
  mod_wn <- lm(y_wn ~ x_wn)

  p_wn[i] <- summary(mod_wn)$coefficient["x_wn", "Pr(>|t|)"]

  #ランダムウォークにするシミュ
  y_rw <- cumsum(rnorm(n = n_sample))
  x_rw <- cumsum(rnorm(n = n_sample))

  #線形回帰分析
  mod_rw <- lm(y_rw ~ x_rw)

  p_rw[i] <- summary(mod_rw)$coefficient["x_rw", "Pr(>|t|)"]
}

#WN
sum(p_wn < 0.05) / n_sim

```

```
[1] 0.055
```

```

#RW
sum(p_rw < 0.05) / n_sim

```

```
[1] 0.85
```

理論値は 0.05であることを考慮すると、0.85 はかなり大きい。

7 見せかけの回帰を防ぐ方法

詳細は note

8

9 単位根検定

#RW への ADF 検定

```
summary(ur.df(y_rw, type = "none"))
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression none

Call:

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.69362	-0.76935	-0.01875	0.61984	3.10863

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
z.lag.1	-0.007932	0.008430	-0.941	0.347
z.diff.lag	-0.037636	0.050540	-0.745	0.457

Residual standard error: 1 on 396 degrees of freedom

Multiple R-squared: 0.004097, Adjusted R-squared: -0.0009326

F-statistic: 0.8146 on 2 and 396 DF, p-value: 0.4436

Value of test-statistic is: -0.9409

Critical values for test statistics:

1pct 5pct 10pct
tau1 -2.58 -1.95 -1.62

```
summary(ur.df(x_rw, type = "none"))
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression none

Call:

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.4968	-0.6984	0.0219	0.8117	3.0420

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
z.lag.1	-0.0008817	0.0030911	-0.285	0.776
z.diff.lag	-0.0148436	0.0501355	-0.296	0.767

Residual standard error: 1.04 on 396 degrees of freedom

Multiple R-squared: 0.0004466, Adjusted R-squared: -0.004602

F-statistic: 0.08847 on 2 and 396 DF, p-value: 0.9153

Value of test-statistic is: -0.2852

Critical values for test statistics:

1pct 5pct 10pct
tau1 -2.58 -1.95 -1.62

1.96 以下である

単位根を持つという帰無仮説を棄却できなかった。

```
#定常 AR(1) 過程への ADF 検定
```

```
summary(ur.df(y_ar,type = "none"))
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

```
Test regression none
```

```
Call:
```

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

```
Residuals:
```

Min	1Q	Median	3Q	Max
-2.94892	-0.57068	-0.04344	0.70965	2.59868

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
z.lag.1	-0.22706	0.03419	-6.641	1.03e-10 ***
z.diff.lag	-0.01848	0.05022	-0.368	0.713

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.9782 on 396 degrees of freedom
```

```
Multiple R-squared:  0.1158,    Adjusted R-squared:  0.1113
```

```
F-statistic: 25.92 on 2 and 396 DF,  p-value: 2.633e-11
```

```
Value of test-statistic is: -6.6414
```

```
Critical values for test statistics:
```

	1pct	5pct	10pct
tau1	-2.58	-1.95	-1.62

```
summary(ur.df(x_ar,type = "none"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression none

Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-3.0561 -0.8481 -0.0768  0.6517  3.8238

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
z.lag.1      -0.30771    0.03843  -8.008 1.32e-14 ***
z.diff.lag   0.03521    0.05003   0.704  0.482
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.089 on 396 degrees of freedom
Multiple R-squared:  0.1516,    Adjusted R-squared:  0.1473
F-statistic: 35.37 on 2 and 396 DF,  p-value: 7.348e-15

Value of test-statistic is: -8.0076

Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

1.96 異常であるので, 単位根がないという帰無仮説を棄却する. 単位根はない.

10 一般化最小二乗法: GLS

詳細は note

11 R による Prains-Winsten 法

まずは残差を求めよう

#定常 AR(1) 過程に従うデータを OLS でモデル化する

```
mod_ols_ar <- lm(y_ar ~ x_ar)
```

#残差

```
resid_ols_ar <- mod_ols_ar$residual
```

残差に対して OLS 推定を行い, 残差の自己相関の推定値を求める

```
mod_resid <- lm(resid_ols_ar[-1] ~ resid_ols_ar[-n_sample]-1)
```

```
ro <- as.numeric(mod_resid$coefficients)
```

```
ro
```

```
[1] 0.7585326
```

初期時点のデータの変換を行う

```
y_trans_1 <- sqrt(1 - ro^2) * y_ar[1]
```

```
x_trans_1 <- sqrt(1 - ro^2) * x_ar[1]
```

```
psi_trans_1 <- sqrt(1 - ro^2)
```

2 時点以降

```
y_trans_2 <- y_ar[-1] - ro*y_ar[-n_sample]
```

```
x_trans_2 <- x_ar[-1] - ro*x_ar[-n_sample]
```

```
psi_trans_2 <- rep(1 - ro, n_sample -1 )
```

二つを結合する

```
y_trans_all <- c(y_trans_1,y_trans_2)
```

```
x_trans_all <- c(x_trans_1,y_trans_2)
```

```
psi_trans_all <- c(psi_trans_1,psi_trans_2)
```

あとは普通に OLS 推定量を求めるだけ

```
mod_gls_hand <- lm(y_trans_all ~ psi_trans_all + x_trans_all -1)
```

```
summary(mod_gls_hand)
```

```

Call:
lm(formula = y_trans_all ~ psi_trans_all + x_trans_all - 1)

Residuals:
      Min       1Q   Median       3Q      Max
-0.00775 -0.00374 -0.00285 -0.00159  0.40275

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
psi_trans_all  0.011590   0.004202   2.758  0.00607 **
x_trans_all    0.998326   0.001047  953.383 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02044 on 398 degrees of freedom
Multiple R-squared:  0.9996,    Adjusted R-squared:  0.9996
F-statistic: 4.551e+05 on 2 and 398 DF,  p-value: < 2.2e-16

```

統計的有意は得られなかった. 見せかけの回帰を回避できた

12 差分系列への回帰分析

単位根があるデータへの回帰分析 (非定常過程に従う)

差分系列に回帰するのが簡単である

```

mod_lm_diff <- lm(diff(y_rw) ~ diff(x_rw))

summary(mod_lm_diff)

```

```

Call:
lm(formula = diff(y_rw) ~ diff(x_rw))

Residuals:
      Min       1Q   Median       3Q      Max
-2.63491 -0.73367  0.04338  0.65956  3.14882

Coefficients:
              Estimate Std. Error t value Pr(>|t|)

```

```
(Intercept) -0.02864    0.05012   -0.571    0.568
diff(x_rw)  -0.01742    0.04818   -0.362    0.718
```

Residual standard error: 1.001 on 397 degrees of freedom

Multiple R-squared: 0.0003292, Adjusted R-squared: -0.002189

F-statistic: 0.1307 on 1 and 397 DF, p-value: 0.7179

13 共和分

共和分の定義は note

変数を y_t と x_t のみとし, 各々は単位根を有する $[I(1)]$ が, 線形結合が定常過程 $[I(0)]$ になる場合を考える.

```
set.seed(1)

rw <- cumsum(rnorm(n = n_sample))      #単位根がある

x_co <- 0.6 * rw + rnorm(n = n_sample)  #単位根がある

y_co <- 0.4 * rw + rnorm(n = n_sample)  #単位根がある
```

なぜ線形結合で単位根が消えるのか

$$z_t = x_t - \frac{0.6}{0.4}y_t$$


上記のような線形結合で RW が消える.

```
#データをまとめる

df <- data.frame(
  y_co = y_co,
  x_co = x_co,
  z = x_co - (0.6/0.4)*y_co
)

#ts 型に変形
ts_df <- ts(df)

#図示
autoplot(ts_df, facets = T)
```

14 共和分検定

単位根を持つデータに対して OLS 推定で回帰直線を求める. 残差を求める

残差に対して単位根検定を行う. 単位根がないなら, 共和分がある.

なぜなら, 回帰式は一種の線型結合だから. 共和分の関係にあれば, 単位根は消えるはず.

```
#データの整形
data_mat <- matrix(nrow = n_sample, ncol = 2)

data_mat[,1] <- y_co

data_mat[,2] <- x_co

#共和分検定

summary(ca.po(data_mat, demean = "none"))
```

```
#####
# Phillips and Ouliaris Unit Root Test #
#####
```

```
Test of type Pu
detrending of series none
```

Call:

```
lm(formula = z[, 1] ~ z[, -1] - 1)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.4650	-0.6586	0.0970	0.9177	3.4208

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
z[, -1]	0.64249	0.00997	64.44	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.251 on 399 degrees of freedom

Multiple R-squared: 0.9123, Adjusted R-squared: 0.9121

F-statistic: 4153 on 1 and 399 DF, p-value: < 2.2e-16

Value of test-statistic is: 236.8936

Critical values of Pu are:

	10pct	5pct	1pct
critical values	20.3933	25.9711	38.3413

共和分がないという帰無仮説が棄却された. 対立仮説を採用する. 共和分関係はある.

共和分関係にあるデータに差分系列への回帰分析を行うと, その関係は見えなくなる

```
#共和分にあるデータに, 差分を取ってから回帰
y_co_diff <- diff(y_co)
x_co_diff <- diff(x_co)

mod_lm_dif_cointegrate <- lm(y_co_diff ~ x_co_diff)
summary(mod_lm_dif_cointegrate)
```

Call:

```
lm(formula = y_co_diff ~ x_co_diff)
```

Residuals:

Min	1Q	Median	3Q	Max
-----	----	--------	----	-----

-4.2689 -0.9975 -0.0603 0.9983 5.4392

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.01614	0.07767	0.208	0.836
x_co_diff	0.03659	0.04712	0.777	0.438

Residual standard error: 1.551 on 397 degrees of freedom

Multiple R-squared: 0.001517, Adjusted R-squared: -0.0009984

F-statistic: 0.603 on 1 and 397 DF, p-value: 0.4379

統計的有意になってないことがわかる. 差分をとればいいってもんじゃない